Laboratorio 8 — Máquinas Vectoriales de Soporte (SVM)

CC3074 — Minería de Datos · Semestre I, 2026

Nicolás Concuá — 23197
Fernando Hernández — 23645
Fernando Rueda — 23748

26 de abril de 2026

1. Preparación de los datos y consideraciones para SVM

El dataset de partida contiene 171,748 registros de propiedades de Airbnb. Después de eliminar filas sin precio válido quedaron 76,246 observaciones. Se creó la variable `price_category` con tres clases (económica, media y cara) usando los percentiles 33 y 66 del precio numérico, con cortes en aproximadamente \$143 y \$268. La partición fue 70/30 estratificada con `random_state=42`, garantizando que cada clase mantuviera alrededor de 33 % tanto en entrenamiento como en prueba.

Para que SVM funcione correctamente fue necesario escalar las variables numéricas con `StandardScaler`, ya que operan en escalas muy distintas (por ejemplo, `maximum_maximum_nights` tiene desviación estándar de millones mientras que `bedrooms` rara vez pasa de 10). Las variables categóricas se codificaron con One-Hot Encoding, reduciendo previamente la cardinalidad a las 20 categorías más frecuentes por columna para evitar matrices excesivamente grandes. El resultado fue una matriz de 134 columnas por observación.

Dado que SVM con kernel RBF o polinomial tiene complejidad $O(n^2)$ a $O(n^3)$, se trabajó con una submuestra fija de 8,000 filas para el tuneo de hiperparámetros, evaluando siempre sobre el conjunto de prueba completo de 22,874 filas.

2. Modelos SVM para clasificación de precios

2.1. Tuneo de hiperparámetros y selección del mejor kernel

Se probaron 13 combinaciones de hiperparámetros mediante `GridSearchCV` con 3 folds estratificados, cubriendo tres kernels (lineal, RBF y polinomial) con distintos valores de C, γ y grado. El mejor modelo fue un SVM con kernel RBF, $C = 1$ y $\gamma =$"scale", que obtuvo una accuracy de validación cruzada de 0.7066.

Cuadro 1: Mejores hiperparámetros por kernel

Kernel	Parámetros	Acc. Train	Acc. Test	Gap
RBF	$C = 1$, γ =scale	0.7831	0.7029	+0.0803
Polinomial	$C = 1$, grado=2, γ =scale	0.7604	0.6916	+0.0688
Lineal	$C = 0{,}1$	0.7136	0.6846	+0.0290

El kernel RBF captura mejor las fronteras no lineales entre categorías de precio. El lineal es más estable (gap menor) pero su accuracy es inferior, y el polinomial queda en un punto intermedio.

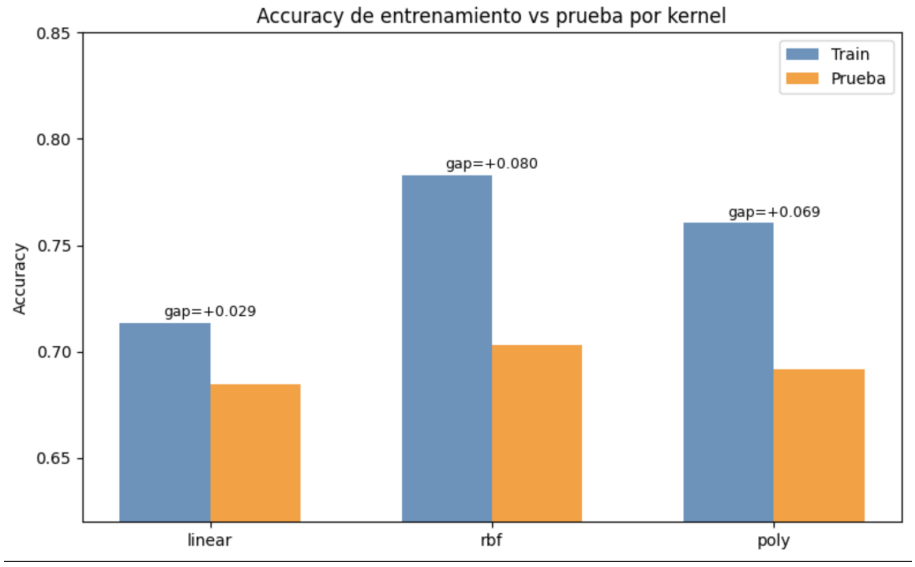

Figura 1: Accuracy de entrenamiento vs prueba por kernel SVM.

2.2. Matrices de confusión y análisis de errores

Las matrices de confusión muestran que la clase "media" es la más difícil de clasificar en los tres kernels, porque las propiedades de precio intermedio comparten características tanto con las económicas como con las caras. El kernel RBF es el que mejor clasifica las tres categorías, con un F1 macro de 0.7025.

Cuadro 2: Métricas por kernel en el conjunto de prueba

Kernel	Accuracy	F1 macro	Precision	Recall
RBF	0.7029	0.7025	0.7029	0.7022
Polinomial	0.6916	0.6928	0.6958	0.6911
Lineal	0.6846	0.6821	0.6811	0.6838

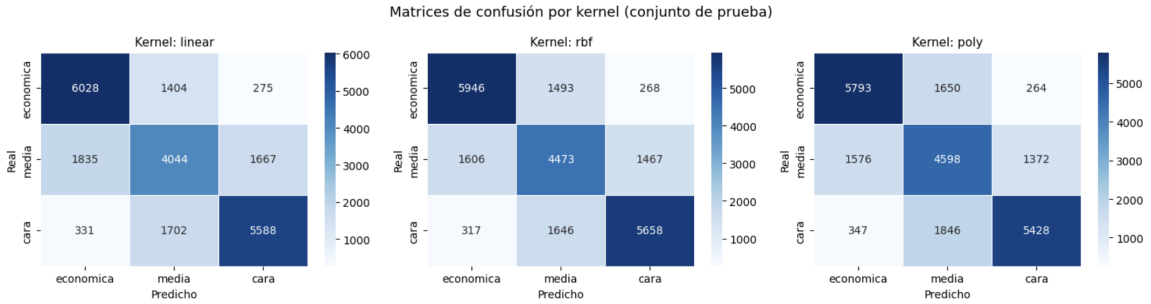

Figura 2: Matrices de confusión por kernel SVM.

Para SmartStay, el error más grave sería clasificar una propiedad cara como económica, porque recomendaría al cliente algo fuera de su presupuesto. Este cruce extremo es el menos frecuente en los tres kernels, lo cual es positivo.

2.3. Sobreajuste en los modelos SVM

El kernel RBF presenta sobreajuste moderado (gap de 0.08), el polinomial también (0.07) y el lineal muestra subajuste leve (gap de 0.03 pero accuracy baja). La curva de aprendizaje del RBF muestra que la brecha se cierra conforme aumenta el tamaño de entrenamiento, lo que confirma que el sobreajuste se debe al tamaño reducido de la submuestra y no a una complejidad excesiva del modelo. Reducir C o usar un γ más pequeño también ayudaría a suavizar las fronteras de decisión.

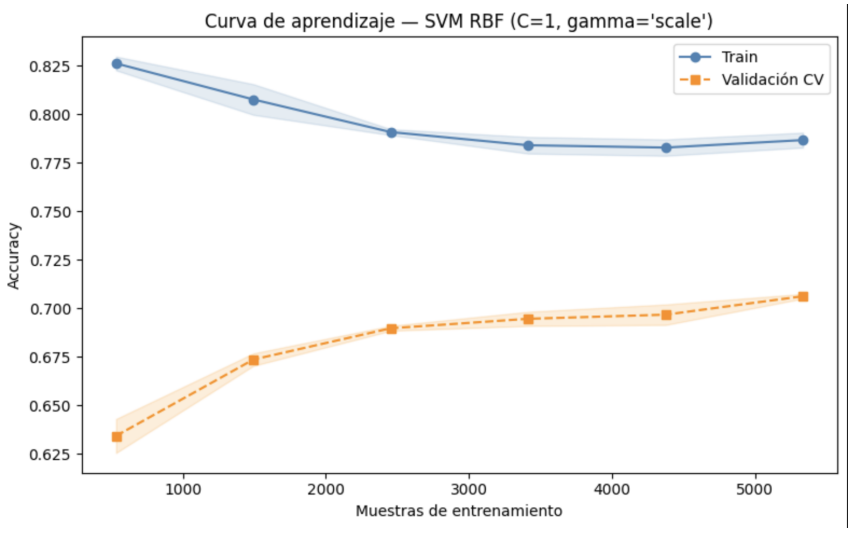

Figura 3: Curva de aprendizaje del SVM RBF ($C = 1$).

3. SVM frente a los modelos de clasificación anteriores

Se comparó el mejor SVM (RBF, $C = 1$) con los modelos de laboratorios anteriores: Árbol de Decisión, Random Forest, Naive Bayes, KNN y Regresión Logística. Todos se evaluaron sobre el mismo conjunto de prueba.

Cuadro 3: Ranking de modelos de clasificación por accuracy en prueba

Modelo	N train	Acc. test	F1 macro	Fit (s)	Pred (s)
Random Forest	53 k	0.7750	0.7746	0.88	0.08
SVM RBF	8 k	0.7029	0.7025	1.30	6.35
Árbol Dec.	53 k	0.6927	0.6944	0.65	0.03
Reg. Logística	53 k	0.6919	0.6911	1.49	0.03
KNN	8 k	0.6356	0.6285	0.02	0.17
Naive Bayes	53 k	0.5634	0.4924	0.13	0.05

Random Forest es el mejor clasificador con 0.7750 de accuracy, aprovechando las 53k filas completas. SVM RBF queda segundo con 0.7029, aunque usa solo 8k filas. Su curva de aprendizaje sugiere que con el dataset completo competiría de cerca con Random Forest, pero el costo computacional lo hace impráctico. En tiempo de predicción, SVM RBF es el más lento (6.35 s) por la evaluación del kernel sobre todos los vectores de soporte. Naive Bayes es el peor modelo por su supuesto de independencia que no se cumple en estas variables.

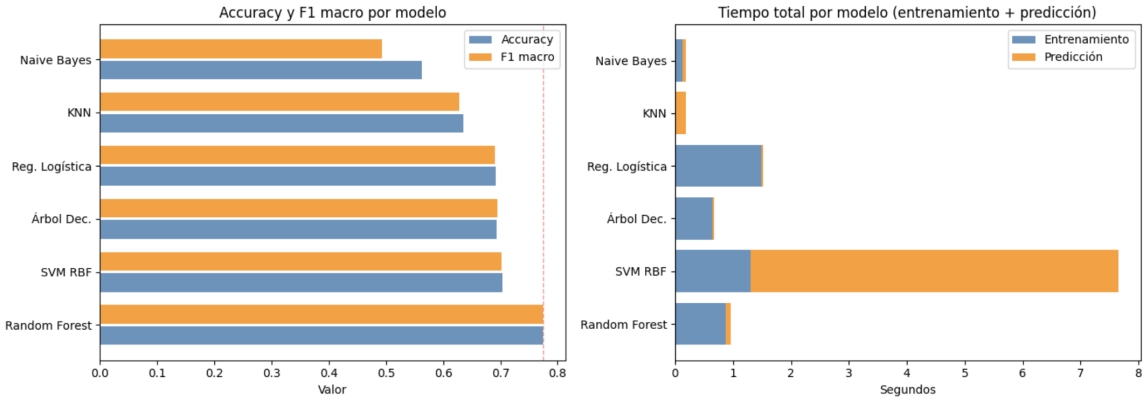

Figura 4: Comparación de accuracy, F1 y tiempo entre todos los modelos de clasificación.

4. Análisis de sobreajuste en todos los modelos de clasificación

Para detectar sobreajuste se compara la accuracy de entrenamiento contra la de prueba. Un gap grande indica que el modelo memoriza el entrenamiento sin generalizar bien.

Cuadro 4: Tabla comparativa de sobreajuste — Clasificación

Modelo	Acc. train	Acc. test	Gap	Diagnóstico
Random Forest	0.9999	0.7750	0.2249	Sobreajuste alto
KNN	0.7680	0.6395	0.1285	Sobreajuste moderado
SVM RBF	0.7831	0.7029	0.0802	Sobreajuste moderado
Árbol Dec.	0.7336	0.6927	0.0409	Ajuste adecuado
Reg. Logística	0.7048	0.6919	0.0129	Ajuste adecuado
Naive Bayes	0.5712	0.5634	0.0078	Desajuste

Random Forest tiene el mayor sobreajuste, con accuracy perfecta en entrenamiento que cae a 0.7750 en prueba. Los 100 árboles sin restricción de profundidad memorizan el dataset completo. KNN y SVM RBF se sobreajustan de forma moderada, principalmente por entrenar con solo 8k filas. El Árbol de Decisión y la Regresión Logística generalizan bien, con gaps menores a 0.05. Naive Bayes tiene gap mínimo pero ambas accuracies son bajas, lo que indica desajuste por su supuesto de independencia.

Para determinar si un modelo está sobreajustado en clasificación hay que comparar las métricas de entrenamiento contra las de prueba (accuracy, F1, loss). Las curvas de aprendizaje permiten ver cómo evoluciona la brecha al aumentar los datos, y la validación cruzada da una estimación más robusta al promediar sobre varias particiones.

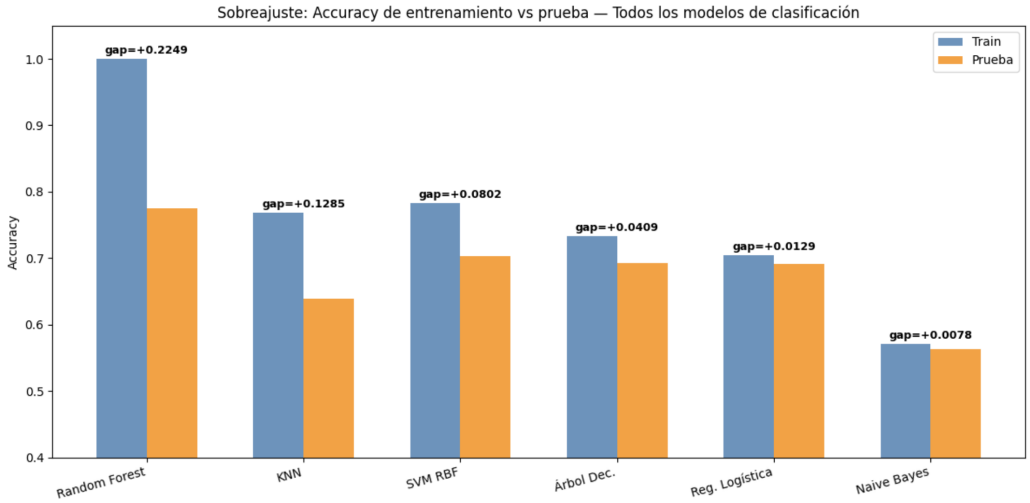

Figura 5: Sobreajuste: accuracy de entrenamiento vs prueba en todos los modelos de clasificación.

5. Modelo SVR para predicción del precio

Para la tarea de regresión se usó SVR (Support Vector Regressor) con `price_num` como variable respuesta continua. Fue necesario aplicar una transformación logarítmica (`log1p`) al precio antes de entrenar, porque la distribución original es extremadamente sesgada (media de \$745, desviación estándar de \$4,236, máximo de \$50,040). Sin esta transformación el modelo daba un R^2 negativo.

Se probaron 47 combinaciones de hiperparámetros con `GridSearchCV`. El mejor modelo fue un SVR con kernel RBF, $C = 10$, $\gamma =$"scale" y $\varepsilon = 0{,}1$.

Cuadro 5: Evaluación del mejor modelo SVR

Métrica	Train	Test
R^2 (escala log)	0.9314	0.7180
RMSE (escala log)	0.2594	0.5293
R^2 (escala \$)	—	0.2595
RMSE (\$)	1,970.73	3,685.78
MAE (\$)	—	412.52

En escala logarítmica el modelo explica el 72 % de la variabilidad del precio, pero al revertir a dólares el R^2 baja a 0.26 porque los errores pequeños en escala log se amplifican exponencialmente en precios altos. El sobreajuste es moderado (gap de 0.21 en R^2 log), explicable por el tamaño de la submuestra de 8,000 filas. El kernel RBF domina todo el top 10 del grid, confirmando que la relación precio-variables es no lineal.

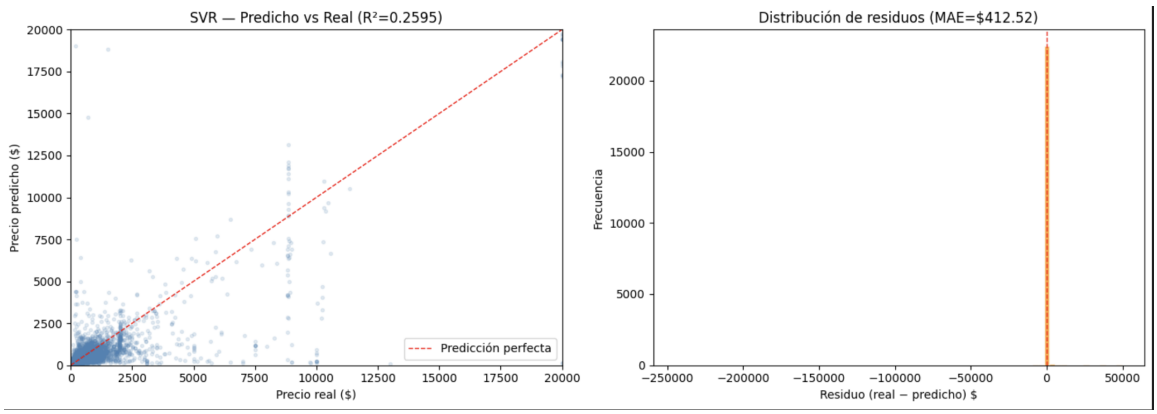

Figura 6: SVR: predicción vs precio real e histograma de residuos.

6. SVR frente a los modelos de regresión anteriores

Los modelos de comparación provienen del lab 6 (KNN), donde se trabajó regresión sobre `price_num` con Regresión Lineal, Árbol de Regresión, Random Forest, Naive Bayes y KNN. Para que la comparación fuera justa se reentrenaron todos en el mismo notebook, con el mismo preprocesamiento, el mismo split y el mismo conjunto de prueba.

Cuadro 6: Ranking de modelos de regresión (escala $)

Modelo	N train	R^2	RMSE ($)	MAE ($)	Total (s)
Random Forest	53 k	0.8732	1,525.14	207.86	11.60
Árbol Reg.	53 k	0.8108	1,863.14	228.42	1.12
KNN	8 k	0.6830	2,411.68	350.10	0.81
Reg. Lineal	53 k	0.5442	2,891.90	807.16	0.22
SVR RBF	8 k	0.2595	3,685.78	412.52	6.65
Naive Bayes	53 k	0.1288	3,997.92	929.53	11.57

Random Forest sigue siendo el mejor modelo de regresión con R^2 de 0.8732 y MAE de $207.86, beneficiándose de las 53k filas y de su capacidad para modelar interacciones no lineales. El SVR quedó quinto de seis, limitado por entrenar con solo 8k filas y por la pérdida de precisión al revertir la transformación logarítmica a dólares. Aun así, su MAE ($412) es mejor que el de Regresión Lineal ($807) y Naive Bayes ($929). KNN con las mismas 8k filas logra un R^2 de 0.68, bastante superior al SVR, lo que indica que para este dataset la predicción por vecinos cercanos funciona mejor que los vectores de soporte.

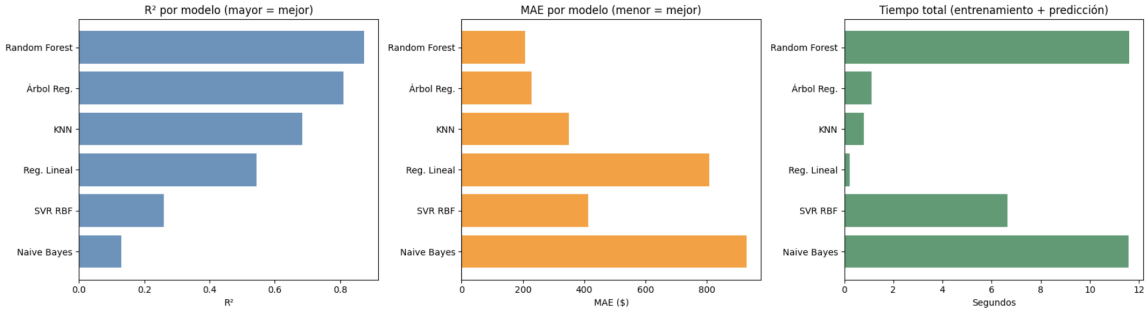

Figura 7: Comparación de R^2, MAE y tiempo entre todos los modelos de regresión.

7. Conclusiones generales

- **Clasificación:** Random Forest es el mejor clasificador (accuracy 0.7750), seguido por SVM RBF (0.7029) que usa solo una fracción de los datos. El kernel RBF supera al lineal y al polinomial porque las fronteras entre categorías de precio no son linealmente separables.
- **Regresión:** Random Forest también domina en regresión ($R^2 = 0{,}8732$). SVR no es competitivo en escala de dólares ($R^2 = 0{,}26$), aunque en escala logarítmica captura bien la estructura del precio ($R^2 = 0{,}72$ en log). Su principal limitante es el costo computacional que obliga a usar submuestras pequeñas.
- **Sobreajuste:** Random Forest presenta el mayor sobreajuste en clasificación (gap 0.22) por memorizar el entrenamiento. SVM RBF tiene sobreajuste moderado (gap 0.08), reducible aumentando los datos de entrenamiento. Regresión Logística y Árbol de Decisión son los más estables.
- **Para SmartStay:** Si la prioridad es maximizar la precisión de las predicciones, Random Forest es la mejor opción tanto para clasificar categorías de precio como para estimar el precio directamente. Si el tiempo de respuesta importa para recomendaciones en tiempo real, Regresión Logística (clasificación) o Árbol de Regresión (predicción de precio) ofrecen el mejor balance entre velocidad y rendimiento. SVM aporta una perspectiva diferente al problema pero su costo computacional lo hace menos práctico con datasets de este tamaño.